

lара-v0.1.2-instruct EN: стаття — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	11.11 [7.78, 14.44]				1.41	8.00	0.11	1.98	84.13	48.04	0.56	0.43
SFT (LoRA, злиті ваги)	неявна	2.89 [1.56, 4.44]	-8.22	50 : 13	3e-06	0.22 (1.41)	0.89 (8.00)	0.01 (0.11)	0.50 (1.98)	17.72 (84.13)	80.70 (48.04)	0.63 (0.56)	0.27 (0.43)
базова модель (без мітигації)	явна	20.22 [15.78, 24.89]				2.12	17.33	0.10	2.73	82.16	50.18	0.57	0.36
SFT (LoRA, злиті ваги)	явна	0.89 [0.22, 2.00]	-19.33	90 : 3	3e-23	0.11 (2.12)	0.67 (17.33)	0.00 (0.10)	0.19 (2.73)	17.54 (82.16)	80.37 (50.18)	0.63 (0.57)	0.31 (0.36)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — $p < 0,05$ (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.