

lара-v0.1.2-instruct UK: стаття — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	13.62 [10.04, 17.19]				1.59	8.02	0.09	2.46	82.94	49.58	0.58	0.41
SFT (LoRA, злиті ваги)	неявна	3.35 [1.78, 5.13]	-10.27	61 : 15	1e-07	0.20 (1.59)	1.11 (8.02)	0.01 (0.09)	0.57 (2.46)	16.70 (82.94)	77.46 (49.58)	0.66 (0.58)	0.09 (0.41)
базова модель (без мітигації)	явна	30.04 [24.32, 35.73]				4.77	24.59	0.11	5.24	74.38	55.66	0.60	0.28
SFT (LoRA, злиті ваги)	явна	2.69 [1.35, 4.26]	-27.35	134 : 12	3e-27	0.36 (4.77)	1.56 (24.59)	0.01 (0.11)	0.56 (5.24)	16.00 (74.38)	77.31 (55.66)	0.65 (0.60)	0.09 (0.28)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — $p < 0,05$ (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.