

Qwen3.5-4B EN: стаття — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	9.11 [6.22, 12.00]				0.79	3.78	0.02	2.10	22.77	80.72	0.69	0.43
SFT (LoRA, злиті ваги)	неявна	5.33 [3.33, 7.56]	-3.78	34 : 17	0.02	0.49 (0.79)	2.22 (3.78)	0.01 (0.02)	0.87 (2.10)	21.71 (22.77)	81.56 (80.72)	0.66 (0.69)	0.34 (0.43)
базова модель (без мітигації)	явна	12.44 [9.11, 15.78]				1.10	6.44	0.03	2.52	33.46	81.97	0.69	0.53
SFT (LoRA, злиті ваги)	явна	6.00 [3.56, 8.67]	-6.44	49 : 20	6e-04	0.50 (1.10)	2.22 (6.44)	0.02 (0.03)	1.09 (2.52)	24.33 (33.46)	82.44 (81.97)	0.66 (0.69)	0.32 (0.53)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — $p < 0,05$ (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.