

Qwen3.5-9B EN: стаття — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	7.11 [4.44, 10.00]				0.56	4.00	0.04	1.16	16.22	79.58	0.67	0.31
SFT (LoRA, злиті ваги)	неявна	4.22 [2.44, 6.44] ♦	-2.89 ♦	29 : 16	0.07	0.43 (0.56)	1.56 (4.00) ♦	0.02 (0.04) ♦	0.83 (1.16) ♦	27.41 (16.22)	82.17 (79.58)	0.65 (0.67)	0.26 (0.31)
SFT (LoRA, злиті ваги)	неявна	4.44 [2.44, 6.67]	-2.67	23 : 11	0.06	0.35 (0.56) ♦	1.78 (4.00)	0.03 (0.04)	0.92 (1.16)	16.97 (16.22)	80.41 (79.58)	0.65 (0.67)	0.23 (0.31) ♦
dpo	неявна	4.67 [2.67, 6.67]	-2.44	30 : 19	0.15	0.64 (0.56)	2.89 (4.00)	0.03 (0.04)	1.03 (1.16)	26.21 (16.22)	82.41 (79.58) ♦	0.60 (0.67)	0.29 (0.31)
dpo	неявна	6.89 [4.22, 9.78]	-0.22	22 : 21	1.00	1.00 (0.56)	5.11 (4.00)	0.11 (0.04)	1.34 (1.16)	12.57 (16.22)	75.83 (79.58)	0.68 (0.67)	0.50 (0.31)
базова модель (без мітигації)	явна	8.22 [5.33, 11.33]				1.05	4.00	0.04	1.78	20.07	81.78	0.68	0.31
dpo	явна	3.78 [2.22, 5.78] ♦	-4.44 ♦	35 : 15	7e-03	0.36 (1.05)	1.56 (4.00)	0.01 (0.04) ♦	0.49 (1.78) ♦	29.13 (20.07)	81.98 (81.78)	0.59 (0.68)	0.30 (0.31)
SFT (LoRA, злиті ваги)	явна	4.00 [2.22, 6.00]	-4.22	31 : 12	5e-03	0.37 (1.05)	1.56 (4.00)	0.01 (0.04)	0.80 (1.78)	28.36 (20.07)	83.07 (81.78) ♦	0.65 (0.68)	0.29 (0.31)
SFT (LoRA, злиті ваги)	явна	4.00 [2.00, 6.22]	-4.22	28 : 9	3e-03	0.32 (1.05) ♦	1.33 (4.00) ♦	0.01 (0.04)	0.80 (1.78)	18.93 (20.07)	81.58 (81.78)	0.65 (0.68)	0.26 (0.31) ♦
dpo	явна	6.22 [3.78, 8.89]	-2.00	30 : 21	0.26	0.83 (1.05)	4.89 (4.00)	0.07 (0.04)	1.03 (1.78)	11.08 (20.07)	76.10 (81.78)	0.68 (0.68)	0.43 (0.31)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — p < 0,05 (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.