

lара-v0.1.2-instruct EN: військовий статус — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	32.00 [26.67, 37.78]				8.75	24.89	0.20	8.93	75.82	53.96	0.56	6.71
SFT (LoRA, злиті ваги)	неявна	3.11 [1.78, 4.67]	-28.89	141 : 11	7e-30	0.32 (8.75)	0.89 (24.89)	0.01 (0.20)	0.84 (8.93)	19.60 (75.82)	80.49 (53.96)	0.63 (0.56)	0.18 (6.71)
базова модель (без мітигації)	явна	23.39 [18.89, 28.29]				6.04	19.76	0.15	6.22	82.40	49.31	0.55	2.49
SFT (LoRA, злиті ваги)	явна	2.45 [1.11, 4.00]	-20.94	103 : 9	2e-21	0.46 (6.04)	1.56 (19.76)	0.01 (0.15)	0.67 (6.22)	18.53 (82.40)	81.02 (49.31)	0.64 (0.55)	0.13 (2.49)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — $p < 0,05$ (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.