

lара-v0.1.2-instruct UK: військовий статус — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	25.39 [20.44, 30.51]				6.85	20.00	0.16	7.56	73.42	56.91	0.59	2.84
SFT (LoRA, злиті ваги)	неявна	2.90 [1.34, 4.67]	-22.49	113 : 12	9e-22	0.25 (6.85)	0.89 (20.00)	0.01 (0.16)	0.67 (7.56)	16.53 (73.42)	77.07 (56.91)	0.65 (0.59)	0.09 (2.84)
базова модель (без мітигації)	явна	17.63 [13.23, 22.54]				4.71	13.97	0.11	5.08	79.16	52.49	0.59	1.42
SFT (LoRA, злиті ваги)	явна	1.34 [0.44, 2.46]	-16.29	79 : 6	2e-17	0.32 (4.71)	0.89 (13.97)	0.01 (0.11)	0.44 (5.08)	16.49 (79.16)	76.93 (52.49)	0.65 (0.59)	0.00 (1.42)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — $p < 0,05$ (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.