

Qwen3.5-9B EN: військовий статус — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	ρ	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	13.33 [8.89, 17.78]				3.86	12.22	0.14	3.82	9.60	74.58	0.64	8.40
SFT (LoRA, злиті ваги)	неявна	3.78 [2.22, 5.34] ♦	-9.56 ♦	59 : 16	6e-07	0.48 (3.86) ♦	1.33 (12.22) ♦	0.02 (0.14)	1.07 (3.82) ♦	28.18 (9.60)	81.69 (74.58)	0.65 (0.64)	0.04 (8.40) ♦
SFT (LoRA, злиті ваги)	неявна	4.00 [2.22, 5.78]	-9.33	55 : 13	3e-07	0.50 (3.86)	2.00 (12.22)	0.03 (0.14)	1.16 (3.82)	18.27 (9.60)	81.20 (74.58)	0.65 (0.64)	0.13 (8.40)
dpo	неявна	4.22 [2.44, 6.22]	-9.11	54 : 13	4e-07	0.55 (3.86)	2.00 (12.22)	0.02 (0.14) ♦	1.11 (3.82)	9.69 (9.60)	75.29 (74.58)	0.68 (0.64)	1.24 (8.40)
prompt: structured_rubric	неявна	5.78 [3.11, 8.44]	-7.56	38 : 4	6e-08	1.44 (3.86)	4.67 (12.22)	0.09 (0.14)	1.82 (3.82)	3.02 (9.60)	69.42 (74.58)	0.62 (0.64)	4.58 (8.40)
dpo	неявна	6.44 [4.22, 8.89]	-6.89	58 : 27	1e-03	1.16 (3.86)	4.00 (12.22)	0.05 (0.14)	1.82 (3.82)	29.11 (9.60)	82.18 (74.58)	0.60 (0.64)	0.09 (8.40)
scrub: llm	неявна	9.11 [6.22, 12.00]	-4.22	42 : 23	0.02	0.69 (3.86)	2.67 (12.22)	0.02 (0.14)	2.71 (3.82)	17.73 (9.60)	80.58 (74.58)	0.67 (0.64)	0.13 (8.40)
prompt: counterfactual_invariance	неявна	10.67 [6.89, 14.67]	-2.67	21 : 9	0.04	2.70 (3.86)	7.78 (12.22)	0.11 (0.14)	2.89 (3.82)	9.16 (9.60)	74.49 (74.58)	0.65 (0.64)	0.84 (8.40)
LEACE (layer 16)	неявна	10.89 [6.89, 15.11]	-2.44	15 : 4	0.02	3.40 (3.86)	9.78 (12.22)	0.15 (0.14)	3.51 (3.82)	6.58 (9.60)	72.44 (74.58)	0.63 (0.64)	5.11 (8.40)
prompt: ignore_personal_info	неявна	10.89 [7.33, 14.44]	-2.44	35 : 24	0.19	2.26 (3.86)	7.11 (12.22)	0.12 (0.14)	2.93 (3.82)	14.40 (9.60)	77.78 (74.58)	0.67 (0.64)	1.11 (8.40)
prompt: reasoning	неявна	11.11 [7.11, 15.11]	-2.22	13 : 3	0.02	2.95 (3.86)	9.56 (12.22)	0.12 (0.14)	3.33 (3.82)	7.91 (9.60)	73.51 (74.58)	0.64 (0.64)	5.56 (8.40)
prompt: recruiter_guidelines	неявна	12.22 [8.22, 16.22]	-1.11	12 : 7	0.36	3.77 (3.86)	9.78 (12.22)	0.13 (0.14)	3.56 (3.82)	8.93 (9.60)	74.09 (74.58)	0.65 (0.64)	5.60 (8.40)
prompt: fairness_constitution	неявна	13.11 [9.78, 16.44]	-0.22	58 : 57	1.00	2.74 (3.86)	8.67 (12.22)	0.11 (0.14)	3.73 (3.82)	26.76 (9.60)	83.82 (74.58) ♦	0.69 (0.64)	0.80 (8.40)
prompt: zero_shot_cot	неявна	14.00 [9.56, 18.67]	+0.67	9 : 12	0.66	4.16 (3.86)	11.78 (12.22)	0.15 (0.14)	4.18 (3.82)	10.76 (9.60)	75.73 (74.58)	0.65 (0.64)	4.89 (8.40)
prompt: second_pass_verification	неявна	18.22 [13.56, 22.89]	+4.89	13 : 35	2e-03	3.02 (3.86)	10.22 (12.22)	0.08 (0.14)	4.98 (3.82)	12.67 (9.60)	76.93 (74.58)	0.64 (0.64)	6.84 (8.40)
scrub: lexical*	неявна	0.00 [0.00, 0.00]	-13.33	60 : 0	2e-18	0.00 (3.86)	0.00 (12.22)	0.00 (0.14)	0.00 (3.82)	16.67 (9.60)	80.22 (74.58)	0.67 (0.64)	0.04 (8.40)
базова модель (без мітигації)	явна	8.44 [5.77, 11.33]				2.36	5.78	0.05	2.49	20.93	82.44	0.68	0.67
dpo	явна	3.56 [1.78, 5.56] ♦	-4.89 ♦	34 : 12	2e-03	0.91 (2.36) ♦	2.67 (5.78) ♦	0.05 (0.05)	1.07 (2.49) ♦	10.09 (20.93)	75.42 (82.44)	0.68 (0.68)	0.31 (0.67)
SFT (LoRA, злиті ваги)	явна	3.78 [2.22, 5.56]	-4.67	34 : 13	3e-03	0.92 (2.36)	2.67 (5.78)	0.02 (0.05) ♦	1.24 (2.49)	29.51 (20.93)	82.67 (82.44) ♦	0.65 (0.68)	0.09 (0.67) ♦
SFT (LoRA, злиті ваги)	явна	3.78 [2.22, 5.56]	-4.67	30 : 9	1e-03	0.91 (2.36)	2.67 (5.78)	0.03 (0.05)	1.16 (2.49)	19.64 (20.93)	82.31 (82.44)	0.65 (0.68)	0.09 (0.67) ♦
dpo	явна	4.67 [2.67, 6.89]	-3.78	33 : 16	0.02	1.03 (2.36)	3.78 (5.78)	0.04 (0.05)	1.24 (2.49)	30.27 (20.93)	82.44 (82.44)	0.59 (0.68)	0.09 (0.67) ♦

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — ρ < 0,05 (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано — виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.