

lара-v0.1.2-instruct EN: релігія — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	23.78 [19.56, 28.44]				2.94	13.11	0.07	5.19	73.14	55.06	0.57	1.09
SFT (LoRA, злиті ваги)	неявна	1.78 [0.67, 3.11]	-22.00	107 : 8	3e-23	0.22 (2.94)	0.89 (13.11)	0.01 (0.07)	0.54 (5.19)	17.80 (73.14)	80.96 (55.06)	0.63 (0.57)	0.00 (1.09)
базова модель (без мітигації)	явна	18.89 [15.11, 22.89]				3.19	13.33	0.14	4.12	75.14	54.20	0.57	0.47
SFT (LoRA, злиті ваги)	явна	0.22 [0.00, 0.67]	-18.67	85 : 1	2e-24	0.04 (3.19)	0.22 (13.33)	0.00 (0.14)	0.02 (4.12)	17.36 (75.14)	80.47 (54.20)	0.63 (0.57)	0.00 (0.47)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — $p < 0,05$ (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.