

lара-v0.1.2-instruct UK: релігія — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	20.67 [16.22, 24.94]				3.84	14.96	0.11	4.74	68.84	59.85	0.61	1.28
SFT (LoRA, злиті ваги)	неявна	3.37 [1.80, 5.15]	-17.30	92 : 15	1e-14	0.68 (3.84)	2.00 (14.96)	0.02 (0.11)	0.99 (4.74)	16.77 (68.84)	77.11 (59.85)	0.65 (0.61)	0.00 (1.28)
базова модель (без мітигації)	явна	24.05 [19.51, 29.02]				5.32	21.21	0.22	5.77	65.19	61.70	0.62	0.12
SFT (LoRA, злиті ваги)	явна	1.11 [0.22, 2.22]	-22.94	108 : 5	3e-26	0.20 (5.32)	0.67 (21.21)	0.01 (0.22)	0.22 (5.77)	15.95 (65.19)	77.09 (61.70)	0.65 (0.62)	0.00 (0.12)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — $p < 0,05$ (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракульна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.