

Qwen3.5-4B UK: релігія — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	ρ	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	15.78 [11.78, 20.00]				2.42	10.44	0.08	3.26	11.78	73.41	0.59	4.57
prompt: structured_rubric	неявна	3.14 [1.57, 4.94] ♦	-12.78 ♦	65 : 8	3e-12	0.35 (2.42) ♦	1.78 (10.44) ♦	0.02 (0.08)	0.57 (3.26) ♦	3.48 (11.78)	68.15 (73.41)	0.57 (0.59)	1.63 (4.57)
SFT (LoRA, злиті ваги)	неявна	6.44 [4.22, 8.89]	-9.33	57 : 15	7e-07	0.57 (2.42)	2.44 (10.44)	0.01 (0.08) ♦	1.65 (3.26)	19.95 (11.78)	77.53 (73.41) ♦	0.65 (0.59)	0.00 (4.57) ♦
prompt: zero_shot_cot	неявна	8.44 [5.78, 11.56]	-7.33	42 : 9	3e-06	1.43 (2.42)	5.78 (10.44)	0.05 (0.08)	1.73 (3.26)	7.95 (11.78)	71.16 (73.41)	0.60 (0.59)	2.07 (4.57)
prompt: recruiter_guidelines	неявна	10.44 [7.33, 13.78]	-5.33	32 : 8	2e-04	1.66 (2.42)	5.78 (10.44)	0.06 (0.08)	2.27 (3.26)	9.46 (11.78)	72.62 (73.41)	0.61 (0.59)	1.80 (4.57)
prompt: reasoning	неявна	12.89 [9.33, 16.89]	-2.89	23 : 10	0.04	1.94 (2.42)	7.56 (10.44)	0.07 (0.08)	2.40 (3.26)	9.26 (11.78)	72.47 (73.41)	0.57 (0.59)	3.73 (4.57)
prompt: ignore_personal_info	неявна	14.67 [10.89, 18.67]	-1.11	25 : 20	0.55	2.06 (2.42)	8.22 (10.44)	0.06 (0.08)	3.38 (3.26)	16.15 (11.78)	75.36 (73.41)	0.61 (0.59)	0.91 (4.57)
scrub: llm	неявна	14.67 [11.11, 18.67]	-1.11	28 : 23	0.58	1.49 (2.42)	6.00 (10.44)	0.04 (0.08)	3.23 (3.26)	14.10 (11.78)	74.20 (73.41)	0.60 (0.59)	2.22 (4.57)
prompt: counterfactual_invariance	неявна	14.89 [11.33, 18.67]	-0.89	29 : 25	0.68	2.68 (2.42)	10.89 (10.44)	0.08 (0.08)	3.41 (3.26)	12.74 (11.78)	73.28 (73.41)	0.59 (0.59)	3.46 (4.57)
prompt: second_pass_verification	неявна	15.78 [11.78, 20.00]	+0.00	23 : 23	1.00	2.06 (2.42)	8.67 (10.44)	0.07 (0.08)	3.73 (3.26)	8.17 (11.78)	70.79 (73.41)	0.57 (0.59)	4.12 (4.57)
prompt: fairness_constitution	неявна	26.73 [22.00, 31.40]	+11.14	57 : 107	1e-04	3.39 (2.42)	21.33 (10.44)	0.07 (0.08)	6.45 (3.26)	36.02 (11.78)	74.15 (73.41)	0.60 (0.59)	0.54 (4.57)
scrub: lexical*	неявна	1.11 [0.22, 2.22]	-14.67	71 : 5	5e-16	0.13 (2.42)	0.44 (10.44)	0.00 (0.08)	0.32 (3.26)	20.15 (11.78)	75.70 (73.41)	0.62 (0.59)	0.00 (4.57)
базова модель (без мітигації)	явна	14.00 [10.66, 17.78]				2.38	7.56	0.05	3.53	24.79	76.20	0.61	0.20
scrub: llm	явна	1.33 [0.44, 2.44] ♦	-12.67 ♦	61 : 4	4e-14	0.15 (2.38) ♦	0.44 (7.56) ♦	0.01 (0.05) ♦	0.37 (3.53) ♦	19.78 (24.79)	75.14 (76.20)	0.61 (0.61)	0.00 (0.20) ♦
SFT (LoRA, злиті ваги)	явна	4.44 [2.67, 6.44]	-9.56	52 : 9	2e-08	0.56 (2.38)	2.44 (7.56)	0.03 (0.05)	1.04 (3.53)	22.62 (24.79)	78.02 (76.20) ♦	0.65 (0.61)	0.00 (0.20) ♦
prompt: structured_rubric	явна	4.71 [2.68, 6.97]	-9.19	59 : 18	3e-06	0.53 (2.38)	2.01 (7.56)	0.03 (0.05)	1.14 (3.53)	7.53 (24.79)	71.07 (76.20)	0.57 (0.61)	0.00 (0.20) ♦
prompt: zero_shot_cot	явна	7.33 [4.89, 10.00]	-6.67	51 : 21	5e-04	0.94 (2.38)	4.22 (7.56)	0.03 (0.05)	1.80 (3.53)	14.49 (24.79)	74.54 (76.20)	0.62 (0.61)	0.07 (0.20)
prompt: recruiter_guidelines	явна	7.78 [5.11, 10.89]	-6.22	44 : 16	4e-04	1.25 (2.38)	4.67 (7.56)	0.03 (0.05)	1.88 (3.53)	16.32 (24.79)	75.83 (76.20)	0.62 (0.61)	0.02 (0.20)
prompt: ignore_personal_info	явна	13.78 [10.67, 17.11]	-0.22	27 : 26	1.00	1.88 (2.38)	9.56 (7.56)	0.06 (0.05)	3.21 (3.53)	28.00 (24.79)	76.10 (76.20)	0.62 (0.61)	0.00 (0.20) ♦
prompt: reasoning	явна	14.67 [11.33, 18.22]	+0.67	28 : 31	0.79	1.81 (2.38)	8.44 (7.56)	0.05 (0.05)	3.04 (3.53)	20.96 (24.79)	75.38 (76.20)	0.60 (0.61)	0.05 (0.20)
prompt: counterfactual_invariance	явна	15.11 [11.56, 18.89]	+1.11	28 : 33	0.61	2.66 (2.38)	8.89 (7.56)	0.06 (0.05)	3.73 (3.53)	23.01 (24.79)	74.52 (76.20)	0.61 (0.61)	0.17 (0.20)
prompt: second_pass_verification	явна	17.11 [13.33, 21.33]	+3.11	10 : 24	0.02	2.38 (2.38)	7.33 (7.56)	0.06 (0.05)	4.42 (3.53)	21.95 (24.79)	76.07 (76.20)	0.61 (0.61)	0.05 (0.20)
prompt: fairness_constitution	явна	20.49 [16.67, 24.67]	+6.68	54 : 84	0.01	3.67 (2.38)	17.68 (7.56)	0.13 (0.05)	4.74 (3.53)	50.30 (24.79)	70.73 (76.20)	0.61 (0.61)	0.05 (0.20)
scrub: lexical*	явна	0.89 [0.22, 1.78]	-13.11	59 : 0	3e-18	0.18 (2.38)	0.89 (7.56)	0.01 (0.05)	0.17 (3.53)	20.02 (24.79)	75.28 (76.20)	0.61 (0.61)	0.00 (0.20)

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — ρ < 0,05 (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат–вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракулярна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.