

Qwen3.5-9B EN: релігія — усі мітигації проти базової моделі на тих самих рядках

Мітигація	Умова	Нестабільні набори % [95% ДІ]	Δ в.п.	Виправл. : зламано	p	MAD в.п. ↓	Розмах AR в.п. ↓	Cohen's h ↓	Неузгодж. % ↓	Найм %	Корисність % ↑	Серед. FS	Згадки атрибута %
базова модель (без мітигації)	неявна	9.11 [5.78, 12.44]				1.89	8.89	0.16	1.93	2.99	69.51	0.60	2.05
SFT (LoRA, злиті ваги)	неявна	2.89 [1.33, 4.67] ♦	-6.22 ♦	41 : 13	2e-04	0.42 (1.89) ♦	1.56 (8.89) ♦	0.01 (0.16) ♦	0.72 (1.93) ♦	27.31 (2.99)	81.73 (69.51)	0.65 (0.60)	0.00 (2.05) ♦
dpo	неявна	4.22 [2.44, 6.22]	-4.89	41 : 19	6e-03	0.57 (1.89)	2.00 (8.89)	0.02 (0.16)	1.01 (1.93)	27.09 (2.99)	82.59 (69.51) ♦	0.60 (0.60)	0.00 (2.05) ♦
SFT (LoRA, злиті ваги)	неявна	5.33 [2.89, 8.00]	-3.78	37 : 20	0.03	0.64 (1.89)	3.11 (8.89)	0.02 (0.16)	1.33 (1.93)	18.37 (2.99)	81.93 (69.51)	0.65 (0.60)	0.00 (2.05) ♦
dpo	неявна	6.67 [4.22, 9.33]	-2.44	33 : 22	0.18	1.14 (1.89)	5.11 (8.89)	0.05 (0.16)	1.28 (1.93)	13.56 (2.99)	76.86 (69.51)	0.68 (0.60)	0.49 (2.05)
базова модель (без мітигації)	явна	7.11 [4.67, 9.78]				0.66	2.44	0.03	1.51	17.85	80.81	0.68	0.00
SFT (LoRA, злиті ваги)	явна	2.67 [1.11, 4.44] ♦	-4.44 ♦	29 : 9	2e-03	0.23 (0.66) ♦	1.11 (2.44)	0.00 (0.03)	0.57 (1.51) ♦	28.52 (17.85)	83.19 (80.81) ♦	0.66 (0.68)	0.00 (0.00) ♦
SFT (LoRA, злиті ваги)	явна	2.67 [1.11, 4.44] ♦	-4.44 ♦	29 : 9	2e-03	0.30 (0.66)	1.11 (2.44)	0.01 (0.03)	0.64 (1.51)	18.89 (17.85)	81.90 (80.81)	0.65 (0.68)	0.00 (0.00) ♦
dpo	явна	3.11 [1.56, 4.89]	-4.00	27 : 9	4e-03	0.40 (0.66)	1.78 (2.44)	0.01 (0.03)	0.89 (1.51)	11.33 (17.85)	75.93 (80.81)	0.68 (0.68)	0.00 (0.00) ♦
dpo	явна	3.11 [1.56, 4.89]	-4.00	30 : 12	8e-03	0.25 (0.66)	0.67 (2.44) ♦	0.00 (0.03) ♦	0.59 (1.51)	29.33 (17.85)	82.86 (80.81)	0.60 (0.68)	0.00 (0.00) ♦

Значення: після мітигації, у дужках — базова модель, обидва на тих самих рядках. Нестабільні набори: частка з власним 95% ДІ (бутстреп за кандидатами); Δ в.п.: зміна відносно базової моделі; жирна кольорова Δ — p < 0,05 (точний знаковий тест виправлених проти зламаних наборів, без корекції). Ран зі збоями парсингу порівнюється лише на повністю розібраних наборах; його власна база на них — під значенням. Курсив ♦ — найкраще значення в стовпці в межах умови (лише реальні мітигації; для частки найму і FS «кращого» напряду немає).

Виправлено : зламано — кожен контрфактичний набір (одна пара кандидат-вакансія, одна умова, усі варіанти атрибута) порівнюється з тим самим набором у базовій моделі. Виправлено: у базовій моделі набір був нестабільним (сам атрибут змінював рішення), після мітигації — стабільний. Зламано: був стабільним, став нестабільним — мітигація внесла нову залежність від атрибута. Δ нестабільних наборів = (зламано – виправлено) / кількість наборів; напр., 58 : 57 означає, що метод виправляє приблизно стільки ж, скільки ламає.

* Лексичне очищення — оракулярна верхня межа, а не порівнювана мітигація: воно вирізає атрибут за власними шаблонами ін'єкцій дослідження, тож кожен варіант посимвольно збігається з CV без атрибута (100% рядків), і модель бачить один і той самий промпт — нульова нестабільність за побудовою. Реальні CV не пишуться нашими шаблонами; цей рядок — лише стеля. Реалістична версія — очищення LLM, яке мусить знайти атрибут саме.